

Recomendaciones generales

Esta guía contiene un Trabajo Práctico de MAAN II. El mismo deben ser resuelto íntegramente en **Python**. La resolución no es simple y se espera que resolverlo tome cierto tiempo por fuera de las clases.

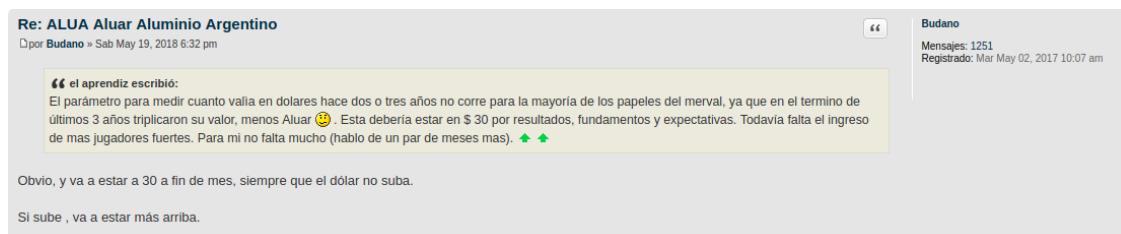
Recuerden que pueden consultarlos sin ningún tipo de problema y que este trabajo y las siguientes son parte de la evaluación que tendrán de la materia. **Sean responsables, no se copien**. Si se detecta copia, toda la guía tendrá un 0 sin excepción. Se sugiere que **empiecen a resolver el TP con tiempo** de modo de tener tiempo para hacer consultas, no andar apurado a último momento.

El Trabajo Práctico debe resolverse de a grupos de **2 o 3 alumnos, no más y no menos**. Las consultas podrán realizarse por mail y en los momentos asignados en clase. Tener en cuenta que **si la consulta es realizada a último momento puede no ser factible responderla**.

Analizando interacciones entre usuarios en foros

En este trabajo práctico vamos a tratar de entender cómo se relacionan usuarios de un foro bursátil online (<http://foro.ravaonline.com/>), para eso vamos a usar todo lo que aprendimos de scraping, análisis de redes sociales y Python. Nuestro objetivo final va a ser armar y analizar una red que indique cómo los usuarios del foro que participaron en tres temas populares del mismo se citaron entre ellos.

El foro está dividido en temas, los mismos suelen estar asociados a algún índice, bono o acción particular. A su vez cada tema está compuesto de posts. Los posts contienen texto escrito por los usuarios. Este texto puede tener emojis, links a artículos fuera del foro, gráficos y citas a posts anteriores escritos en el tema. Además del texto escrito, cada post contiene metadata que indica qué usuario lo escribió y cuándo lo hizo. La siguiente figura muestra un post del foro del Grupo Financiero Galicia (GGAL):



El post fue hecho por el usuario *Budano* el 19 de Mayo y cita un comentario del usuario *el aprendiz*.

Este trabajo práctico va a estar dividido en tres etapas, simulando lo que podría ser un flujo posible al momento de abordar esta tarea en la práctica. Las etapas son:

1. (3 puntos) Armado del scraper y obtener los datos crudos (el HTML de las páginas de cuatro temas de los foros. Por ejemplo, se pueden usar *DIA Dow Jones*, *GGAL*, *COME* y *ALUA*. Dado que bajar y guardar todos los posts de un tema grande puede consumir excesivos recursos (tiempo y memoria), el scrapper que implementen se tiene que limitar a bajar las primeras 300 páginas de cada tema. Si un tema tuviera menos de 300 páginas, se deben bajar todos su posts. Noten que `scraper.py` tiene incorporado una guarda que capta esta idea. Se pide exportar cada tema guardando el `html` plano en una lista de strings usando el módulo `pickle`.
2. (3.5 puntos) Formulación del modelo de la red de citas (dirigido vs. no dirigido, con pesos vs. sin pesos, etc.) e hipótesis de análisis (que se quiere analizar). Hay más de una opción posible, cada grupo deberá justificar la elección del modelo y los objetivos del estudio. Con el modelo en mente, se procesan los datos para armar la instancia del mismo. Para este ejercicio no se entrega una base, que podrá ser modificada por el grupo, en `graph.generator.py`. Lo que ustedes deben hacer es, en base a los datos recolectados con el scraper, es armar la red de citas entre usuarios que participaron en los tres temas para los que se bajaron datos. A los fines de que puedan avanzar con la implementación de este ejercicio en paralelo, se entrega un archivo con una muestra reducida de páginas de un tema. *Sugerencia: se recomienda modularizar el código con funciones, a fin de que sea más simple trabajar con él y reutilizar código.*

Para la extracción de la información de los `html` guardados se utiliza el módulo `BeautifulSoup`, y se proveen tres funciones que encapsulan su utilización a modo de facilitar el proceso. Las mismas son:

- `get_posts(html)`: recibe el `html` de una de las páginas exportadas y retorna una lista con los *posts* que extrae de la misma. Los posts corresponden a instancias de clases particulares de `Beautiful Soup`, pero eso no debería importar.
 - `get_post_user(post)`: toma un post (como los retornados por la función `get_posts`) y retorna el `string` con el nombre del usuario que realizó el post.
 - `get_post_cites(post)`: toma un post (como los retornados por la función `get_posts`) y retorna la lista de usuarios a los que citó el autor del post. *Observación: esta lista puede ser vacía (no hay citas en el post), tener un único usuario (una única cita en el post) o tener múltiples elementos (más de una cita en el post).*
3. (3.5 puntos) Análisis de la red de citas en términos de métricas habituales sobre redes, estructura, características de centralidad e importancia y relaciones entre los usuarios, visualizaciones, etc. El análisis debe estar soportado por los datos y métricas calculadas, y se tomará positivamente la utilización combinada entre *gephi* y *networkx*.

Modalidad de entrega

Junto a cada uno de los ejercicios se les pide que presenten un mini informe de no más de seis carillas en donde detallen qué es lo que han hecho, qué decisiones tomaron para resolver el ejercicio y se responda (en caso de haber) las consignas y preguntas planteadas, dando una interpretación de los resultados obtenidos. Adicionalmente, se pide que todo código que entreguen esté bien comentado y sea entendible.

Fechas de entrega

Formato Electrónico: **viernes 25 de Junio, hasta las 23:59 hs.**, enviando el trabajo (informe + código) a las direcciones `maan2utdt@gmail.com`. El subject del email debe comenzar con el texto [TP4 MAAN II] seguido de la lista de apellidos de los integrantes del grupo. Todos los integrantes del grupo deben estar copiados en el email.

Importante: El horario es estricto. Los correos recibidos después de la hora indicada serán considerados re-entrega.